


UNIVERSIDADE FEDERAL DE UBERLÂNDIA
FACULDADE DE ENGENHARIA ELÉTRICA
PÓS-GRADUAÇÃO EM ENGENHARIA ELÉTRICA



**Inserção Automática de Componentes
em Ambientes Virtuais de Treinamento para Subestações
de Energia utilizando Inteligência Artificial**

Leandro Sena Zuza

Uberlândia

2024

Leandro Sena Zuza

Inserção Automática de Componentes em Ambientes Virtuais de Treinamento para Subestações de Energia utilizando Inteligência Artificial

Dissertação apresentada ao Programa de Pós-graduação em Engenharia Elétrica da Universidade Federal de Uberlândia, como parte dos requisitos exigidos para obtenção do Título de Mestre em Ciências.

Julho X, 2024.

Membros da Banca:

Prof. Alexandre Cardoso, Dr.
Orientador - UFU

Prof. Daniel S. Caetano, Dr.
Coorientador - UFU

Agradecimentos

[INSERIR NOVOS AGRADECIMENTOS]

“Então considere que as botas apertadas são uma das maiores venturas da Terra,
porque, fazendo doer os pés, dão azo ao prazer de as descalçar.”
(Machado de Assis, em Memórias Póstumas de Brás Cubas)

Abstract

The precise identification of equipment in images plays a crucial role in various operations related to power substations, facilitating not only maintenance but also the monitoring of these facilities. In this work, we present results on the efficiency of YOLOv8 in detecting equipment present in power substations from images obtained by Unmanned Aerial Vehicles (UAVs). We employ different optimization techniques to enhance detection efficiency, aiming to achieve more accurate and faster results. Additionally, this study aims to go beyond mere training with captured photos, seeking to identify the best-trained model to create a script capable of selecting, from a database of virtual reality models, the elements necessary for assembling a virtual power substation. Thus, we aim not only to improve the maintenance and monitoring processes of power substations in physical reality but also to streamline and enhance the generation of Virtual Training Environments for procedures related to these substations. With this advancement, we hope to not only optimize the use of detection technology in power substations but also to significantly contribute to the creation of realistic and efficient virtual environments for training in procedures related to the operation and maintenance of these facilities.

Keywords

Keywords - Power Substation; UAV; YOLOv8; Optimization; Virtual Training Environments

Resumo

A identificação precisa de equipamentos em imagens desempenha um papel crucial em várias operações relacionadas às subestações de energia, facilitando não apenas a manutenção, mas também o monitoramento dessas instalações. Neste trabalho, apresentamos resultados da eficiência da YOLOv8 na detecção de equipamentos presentes em subestações de energia, a partir de imagens obtidas por Veículos Aéreos Não Tripulados (VANTs). Utilizamos diferentes técnicas de otimização para aprimorar a eficiência na detecção, visando alcançar resultados mais precisos e rápidos. Além disso, este estudo visa ir além do mero treinamento com as fotos capturadas, buscando identificar o melhor modelo treinado para criar um script capaz de selecionar, a partir de uma base de modelos de realidade virtual, os elementos necessários para a montagem de uma subestação de energia virtual. Dessa forma, almejamos não apenas melhorar os processos de manutenção e monitoramento das subestações de energia na realidade física, mas também agilizar e aprimorar a geração de Ambientes Virtuais de Treinamento para procedimentos relacionados a essas subestações. Com este avanço, esperamos não só otimizar o uso de tecnologia de detecção em subestações de energia, mas também contribuir significativamente para a criação de ambientes virtuais realistas e eficientes para treinamento em procedimentos relacionados à operação e manutenção dessas instalações.

Palavras Chave

Subestação de Energia; VANTs; YOLOv8; Otimização; Ambientes Virtuais de Treinamento

Publicações

As publicações relacionadas à pesquisa e ao trabalho realizado são listadas a seguir:

1. Zuza, L. S., Cardoso, A., Lamounier, E., & Caetano, D. (2024). Análise dos Parâmetros da YOLOv8 na eficiência da identificação de reatores de núcleo de ar a partir de imagens de subestações de energia. In: *CISTI'2024 - 19^a Conferência Ibérica de Sistemas e Tecnologias de Informação*, 25-28 de junho de 2024, Salamanca, Espanha.

Sumário

1	TRABALHOS RELACIONADOS	1
1.1	Introdução	1
1.2	Treinamento utilizando RNC e Alteração de Parâmetros da RNC . .	1
1.2.1	Identificação e Medição de Defeitos em Produtos Automotivos Usando Visão Computacional	1
1.3	Aplicação YOLOv8 e Utilização de VANT	2
1.3.1	Subseção 3	2
1.3.2	Subseção 4	2
1.4	Considerações Finais	2
	REFERÊNCIAS	4

Lista de ilustrações

Figura 1 – Exemplo de marcação de foto, utilizando labelImg, de um defeito em um vidro (GONZAGA, 2023)	1
Figura 2 – Resultado do trabalho de (GONZAGA, 2023), variando os tipos de rede Yolo na versão 5, assim como o otimizador e o batch	2

Lista de tabelas

Tabela 1 – Resumo comparativo dos trabalhos relacionados	3
--	---

Lista de abreviaturas e siglas

VANT	Veículo Aéreo Não Tripulado
RV	Realidade Virtual
NA	Neurônio Artificial
RNC	Rede Neural Convolucional
YOLO	You Look Only Once
GD	Gradiente Descendente
SGD	Stochastic Gradient Descent
ADAM	Adaptive Moment Estimation

1 Trabalhos Relacionados

1.1 Introdução

O presente capítulo apresenta os trabalhos relacionados à utilização de RNC para treinamento de imagens, com e sem variação de parâmetros; a trabalhos em que há a aplicação específica a versão 8 da YOLO; aqueles que utilizaram VANT e os que criaram automação para sistemas de Realidade Virtual. Objetiva-se com isso encontrar o estado da arte de cada trabalho, elencando as principais contribuições de cada trabalho.

No final do capítulo, compara-se os estudos de modo a justificar o presente sistema abordado neste trabalho.

1.2 Treinamento utilizando RNC e Alteração de Parâmetros da RNC

1.2.1 Identificação e Medição de Defeitos em Produtos Automotivos Usando Visão Computacional

O trabalho apresentado por (GONZAGA, 2023) investigou a aplicabilidade e eficácia de um sistema de visão computacional para identificar defeitos visuais, medindo os respectivos tamanhos, no controle de qualidade de uma empresa de reposição de vidros automotivos. A fim de automatizar a decisão de precificação dos itens defeituosos, de maneira replicável e confiável foi utilizada a RNC YOLOv5.

Para o treinamento, foram analisadas 3.397 imagens com defeitos específicos da rotina da empresa. De todos esses, foram selecionadas 70




Figura 1 – Exemplo de marcação de foto, utilizando labelImg, de um defeito em um vidro (GONZAGA, 2023)

Para obtenção do melhor resultado, foram variados os tamanhos do valor do batch size (entre 2 e 32), além alterar para cada configuração desta, seu comportamento com três possibilidades de otimizadores diferentes: SGD, Adam e AdamW. A YOLO, em sua versão 5, oferece variações da arquitetura para diferentes propósitos. Neste trabalho, foram variadas 10 variações, juntamente com a alteração de parâmetros. Todos os outros hiperparâmetros foram mantidos na configuração padrão. Cada treinamento foi realizado em 300 épocas.

		OTIMIZADOR															
		Adam				AdamW				SGD							
A R Q U I T E S T E S	YOLOv5n	0,27538	0,34865	0,38961	0,41080	0,43883	0,43552	0,49647	0,57268	0,55400	0,56654	0,64075	0,65211	0,64726	0,66364	0,66875	
	YOLOv5s	0,34196	0,36912	0,39459	0,44227	0,48022	0,48880	0,57605	0,59021	0,60678	0,60352	0,65083	0,68531	0,67008	0,66049	0,71152	
	YOLOv5m	0,29176	0,29275	0,39649	0,39963	0,44942	0,44095	0,58621	0,60273	0,61912	0,61064	0,69482	0,69744	0,71047	0,7046	0,68441	
	YOLOv5l	0,22021	0,27619	0,35365	0,39097	-	0,40879	0,40413	0,52815	0,55821	-	0,68594	0,70907	0,71805	0,70633	-	
	YOLOv5x	0,21386	0,29198	0,33194	0,35104	-	0,51829	0,53109	0,40974	0,60228	-	0,71413	0,71037	0,72921	0,70505	-	
	YOLOv5x6	0,26231	0,31297	0,41337	0,44406	0,47405	0,44321	0,48123	0,57403	0,61179	0,59240	0,71131	0,70117	0,69676	0,70092	0,70257	
	YOLOv5x6	0,22994	0,30712	0,34329	0,44475	-	0,46749	0,50013	0,58957	0,62237	-	0,71564	0,70941	0,71138	0,72084	-	
	YOLOv5x6	0,28451	0,34193	0,32272	-	-	0,46582	0,49921	0,51498	-	-	0,70402	0,71544	0,72812	-	-	
	YOLOv5x6	0,30023	0,39947	-	-	-	0,49962	0,56281	-	-	-	0,71112	0,71016	-	-	-	
	YOLOv5x6	0,32116	0,38698	-	-	-	0,51172	0,55710	-	-	-	0,70572	0,71120	-	-	-	
		Batch 2	Batch 4	Batch 8	Batch 16	Batch 32	Batch 2	Batch 4	Batch 8	Batch 16	Batch 32	Batch 2	Batch 4	Batch 8	Batch 16	Batch 32	
		BATCH SIZE															

Figura 2 – Resultado do trabalho de (GONZAGA, 2023), variando os tipos de rede Yolo na versão 5, assim como o otimizador e o batch

O otimizador SGD, na variação YOLOv5x, com a o batch size de 8, alcançou a melhor precisão média, ou seja, um mAP de 0,72921. Com esta automatização, nos testes com a aplicação da detecção, houve uma precisão de 83,33

1.3 Aplicação YOLOv8 e Utilização de VANT

1.3.1 Subseção 3

1.3.2 Subseção 4

1.4 Considerações Finais

Inserir considerações finais.

A tabela 1 apresenta um resumo de todos os trabalhos relacionados descritos nesse capítulo, considerando os seguintes temas:

- *Treinamento utilizando RNC*: utilização de RNC para realizar treinamento em conjunto de imagens;
- *Alteração de Parâmetros da RNC para treinamento*: variação de parâmetros como batch e otimizadores para treinamento;
- *Automação de Inserção de RV*: construir sistema de inserção automática de objetos em um sistema de RV;

Tabela 1 – Resumo comparativo dos trabalhos relacionados

Trabalhos Relacionados	Treinamento utilizando RNC	Alteração de Parâmetros da RNC	Aplicação YOLOv8	Utilização de VANT	Subestações de Energia	Automação de Inserção de RV
(GONZAGA, 2023)	✓	✓	×	×	×	×

- *Aplicação YOLOv8*: utilização da versão 8 da YOLO para realizar treinamentos;
- *Utilização de VANT*: realizar coleta de fotos utilizando VANT; e
- *Subestações de Energia*: realizar toda coleta, treinamento e inserção voltado para Subestações de Energia.

Pela análise da Tabela 1, it is possible to note that until the present moment, a system with all features above, has not been found in the literature. It's believed that through these features, the user and therapist will be connected to a training environment and interacting in a more natural, secure, and efficient way. The idea is to have a user who, from any place with Internet and a computer, will issue commands necessary to control a PW and, at the same time, will receive visual augmented feedback in a traditional monitor device. Each user has different impairments and thus the therapist can set up a specific amount of tasks that will make part of the training protocol. Therefore, this research proposes the investigation of computer techniques that support the integration of all these features.

No próximo capítulo, detalha-se os materiais e métodos utilizados para a solução proposta.

Referências

GONZAGA, L. M. Identificação e medição de defeitos em produtos automotivos usando visão computacional. Serra, 2023. Citado 4 vezes nas páginas 9, 1, 2 e 3.