


UNIVERSIDADE FEDERAL DE UBERLÂNDIA
FACULDADE DE ENGENHARIA ELÉTRICA
PÓS-GRADUAÇÃO EM ENGENHARIA ELÉTRICA



**Inserção Automática de Componentes
em Ambientes Virtuais de Treinamento para Subestações
de Energia utilizando Inteligência Artificial**

Leandro Sena Zuza

Uberlândia

2024

Leandro Sena Zuza

**Inserção Automática de Componentes
em Ambientes Virtuais de Treinamento para Subestações
de Energia utilizando Inteligência Artificial**

Dissertação apresentada ao Programa de Pós-graduação em Engenharia Elétrica da Universidade Federal de Uberlândia, como parte dos requisitos exigidos para obtenção do Título de Mestre em Ciências.

Julho X, 2024.

Membros da Banca:

Prof. Alexandre Cardoso, Dr.
Orientador - UFU

Prof. Daniel S. Caetano, Dr.
Coorientador - UFU

Agradecimentos

[INSERIR NOVOS AGRADECIMENTOS]

“Então considere que as botas apertadas são uma das maiores venturas da Terra,
porque, fazendo doer os pés, dão azo ao prazer de as descalçar.”
(Machado de Assis, em Memórias Póstumas de Brás Cubas)

Abstract

The precise identification of equipment in images plays a crucial role in various operations related to power substations, facilitating not only maintenance but also the monitoring of these facilities. In this work, we present results on the efficiency of YOLOv8 in detecting equipment present in power substations from images obtained by Unmanned Aerial Vehicles (UAVs). We employ different optimization techniques to enhance detection efficiency, aiming to achieve more accurate and faster results. Additionally, this study aims to go beyond mere training with captured photos, seeking to identify the best-trained model to create a script capable of selecting, from a database of virtual reality models, the elements necessary for assembling a virtual power substation. Thus, we aim not only to improve the maintenance and monitoring processes of power substations in physical reality but also to streamline and enhance the generation of Virtual Training Environments for procedures related to these substations. With this advancement, we hope to not only optimize the use of detection technology in power substations but also to significantly contribute to the creation of realistic and efficient virtual environments for training in procedures related to the operation and maintenance of these facilities.

Keywords

Keywords - Power Substation; UAV; YOLOv8; Optimization; Virtual Training Environments

Resumo

A identificação precisa de equipamentos em imagens desempenha um papel crucial em várias operações relacionadas às subestações de energia, facilitando não apenas a manutenção, mas também o monitoramento dessas instalações. Neste trabalho, apresentamos resultados da eficiência da YOLOv8 na detecção de equipamentos presentes em subestações de energia, a partir de imagens obtidas por Veículos Aéreos Não Tripulados (VANTs). Utilizamos diferentes técnicas de otimização para aprimorar a eficiência na detecção, visando alcançar resultados mais precisos e rápidos. Além disso, este estudo visa ir além do mero treinamento com as fotos capturadas, buscando identificar o melhor modelo treinado para criar um script capaz de selecionar, a partir de uma base de modelos de realidade virtual, os elementos necessários para a montagem de uma subestação de energia virtual. Dessa forma, almejamos não apenas melhorar os processos de manutenção e monitoramento das subestações de energia na realidade física, mas também agilizar e aprimorar a geração de Ambientes Virtuais de Treinamento para procedimentos relacionados a essas subestações. Com este avanço, esperamos não só otimizar o uso de tecnologia de detecção em subestações de energia, mas também contribuir significativamente para a criação de ambientes virtuais realistas e eficientes para treinamento em procedimentos relacionados à operação e manutenção dessas instalações.

Palavras Chave

Subestação de Energia; VANTs; YOLOv8; Otimização; Ambientes Virtuais de Treinamento

Publicações

As publicações relacionadas à pesquisa e ao trabalho realizado são listadas a seguir:

1. Listar aqui

Contents

1	INTRODUÇÃO	1
1.1	Motivação	1
1.2	Objetivos e Metas	3
1.3	Estrutura da Dissertação	3
2	FUNDAMENTAÇÃO TEÓRICA	4
2.1	Subestações de Energia	4
2.2	Redes Neurais	4
2.2.1	You Look Only Once	6
2.2.2	Batch	6
2.2.3	Otimizadores	7
2.2.4	Precisão e Recall	7
2.3	Realidade Virtual	8
2.4	Considerações finais	9
	BIBLIOGRAPHY	10

List of Figures

Figure 1 – Cálculo de IoU. (PADILLA; NETTO; SILVA, 2020)	8
Figure 2 – Aumento de desempenho da precisão média, versão 5 para 8. (JOCHER; CHAURASIA; QIU, 2023)	8

List of Tables

List of abbreviations and acronyms

VANT	Veículo Aéreo Não Tripulado
------	-----------------------------

1 Introdução

1.1 Motivação

As subestações de energia desempenham um papel fundamental no sistema de distribuição de energia elétrica no Brasil, permitindo a transferência eficiente e segura de eletricidade entre diferentes níveis de tensão. Elas são cruciais para garantir que a eletricidade gerada em usinas seja entregue aos consumidores com a qualidade e confiabilidade necessárias. Efetivamente, desempenham um papel crucial na estabilidade do sistema elétrico, facilitando a manutenção, controle e proteção da rede. Seu funcionamento envolve várias etapas, começando com a recepção da eletricidade gerada em usinas de energia. A eletricidade é então transformada em níveis de tensão adequados para distribuição por meio de transformadores. Nas subestações, também ocorrem operações de chaveamento, onde os dispositivos de comutação são usados para controlar o fluxo de eletricidade e direcioná-lo para as áreas desejadas da rede. As subestações também estão equipadas com sistemas de proteção que detectam e isolam falhas para evitar danos ao sistema elétrico e garantir a segurança dos equipamentos e dos operadores (RANDOLPH, 2013).

Contudo falhas de segurança durante as rotinas de um colaborador não são raras no setor elétrico, podendo causar danos a sua saúde, e em alguns casos levando a óbito. De acordo com o estudo de (LIMA; OLIVEIRA, 2021), acidentes de trabalho são muito comuns em ambientes como subestações de energia. Para avaliar as causas, foram analisados diversos processos trabalhistas durante um período de tempo contra empresas que prestam serviço neste setor. Foram concluídas as existências de várias as causas, mas uma se destaca: a falta de treinamento. No estudo citado, este fato é atrelado à terceirização dos serviços. Enquanto um funcionário direto da companhia de energia da região recebia 6 meses de treinamento, o funcionário terceirizado era treinado em um período médio de 30 a 40 dias. A qualidade do conteúdo destes treinamentos para o funcionário terceirizado também era muito mais superficial. Em uma análise dentro deste estudo, a respeito de um acidente fatal, foi verificado que um técnico foi acionado para resolução de um problema de rompimento de cabo. Devido a um descuido, um dos colaboradores tocou em um cabo energizado, sem se preocupar em verificar se todas as chaves estariam desligadas, acabando por o levar a óbito. Deste estudo, portanto, entendeu-se que a busca por custos mais baixos durante o treinamento, pessoas que se expõem ao risco, e o próprio funcionamento da transmissão de energia é colocado à prova.

Nesse cenário, intervenções tecnológicas seriam de grande valia para melhorar a condição de treinamento de operadores no sistema elétrico. São diversas as possibilidades de aplicações que podem atuar nesse sentido, desde sistemas avançados de monitoramento

até soluções de Realidade Virtual (RV), oferecendo oportunidades para aprimorar a gestão e operação das subestações. A incorporação dessas inovações, podem levar as empresas do setor elétrico a oferecer maior segurança aos seus colaboradores, reduzir custos operacionais e garantir um fornecimento de energia mais confiável para os consumidores finais (ZHOU; FU; YANG, 2016).

Para funções didáticas, como treinamentos, a RV se destaca como uma abordagem disruptiva em relação a métodos tradicionais, principalmente pelo alto nível de imersibilidade no contexto da aplicação, proporcionado ao usuário e ao alto resultado no aprendizado do conteúdo trabalhado. Contudo, para construir e preparar todo o ambiente para uma experiência imersiva em RV, faz-se necessário a elaboração de uma complexa estrutura que envolve desde a escolha do equipamento que será utilizado para a projeção ao usuário, como por exemplo, uma caverna de visualização, capacete de virtualização ou mesmo óculos de RV, até a criação, em softwares próprios para esse tipo de desenvolvimento, toda modelagem gráfica do ambiente até as interações que existentes na aplicação. Fatores como a capacidade gráfica e técnica são levadas em consideração nesta etapa, uma vez que aplicações com grande quantidade de interações e elementos, exigem do hardware que irá renderizar elevada capacidade de processamento. Se a demanda pela capacidade for alta, e não for suportada pelo hardware, será exigido do desenvolvedor redução na qualidade das texturas, assim como outros tratamentos para que toda a experiência durante a imersão não seja lenta ou mesmo careça de elementos que destitua a aplicação de imersibilidade (PALMEIRA et al., 2020).

Outro recurso que tem sido aplicado em várias áreas da ciência são as Redes Neurais Artificiais (RNA). Sua utilização tem sido atrelado a resolução de sistemas não-lineares em que nem todas as variáveis do problema são conhecidas, assim como problemas em que exista ruídos nos dados a serem tratados, ou seja, ideais para problemas do mundo real quando transportados para o mundo virtual. Ao simular o funcionamento do cérebro humano, replicando o aprendizado natural, as RNA exibem a capacidade de resolver problemas complexos, sendo, assim, ferramenta ótima a ser associada a um trabalho de pesquisa (OĞCU; DEMIREL; ZAIM, 2012).

Deste modo, motivado pela possibilidade de elaborar uma ferramenta que simplifique o desenvolvimento de um sistema em RV voltado para aplicações de treinamento de colaboradores em subestações de energia, este trabalho se propõe a construir uma ferramenta que faça a inserção automática de componentes em um ambiente de RV de uma subestação de energia. Toda a automação será alimentada por um modelo treinado a partir de uma RNA, alimentada por fotos capturadas por VANTs em duas subestações de energia diferentes.

1.2 Objetivos e Metas

O objetivo geral desta pesquisa é propor um sistema de inserção automática de componentes em ambientes virtuais de treinamento para subestações de energia a partir de imagens aéreas coletadas do local a ser mapeado virtualmente. Para alcançar esse objetivo geral, foram estabelecidos os seguintes objetivos específicos:

- Realizar uma revisão da literatura científica, para identificar quais os algoritmos utilizados no reconhecimento de padrões em imagens aéreas obtidas por VANTs;
- Estudar e avaliar quais são os hiperparâmetros do algoritmo de inteligência artificial a ser utilizado, que garanta maior eficiência no reconhecimento de componentes das subestações elétricas;
- Desenvolver uma automação capaz de receber uma imagem, reconhecer componente(es) da subestação elétrica inserir no ambiente virtual.

1.3 Estrutura da Dissertação

A presente dissertação é composta por sete capítulos, descritos da seguinte forma.

- No Capítulo 1 são apresentadas as motivações, os objetivos e a estruturação do trabalho;
- No Capítulo 2 são apresentados os principais fundamentos teóricos relacionados ao trabalho;
- No Capítulo 3 é apresentado o estado da arte da linha de pesquisa principal desse trabalho;
- Nos Capítulos 4 e 5 são apresentados materiais/métodos e detalhes de implementação;
- No Capítulo 6, são discutidos e apresentados os resultados obtidos nesse trabalho a partir do sistema desenvolvido;
- Por fim, no Capítulo 7, são apresentadas as conclusões e as perspectivas para trabalhos futuros.

2 Fundamentação Teórica

2.1 Subestações de Energia

As subestações desempenham um papel crucial na transmissão e distribuição de energia elétrica. Quando a eletricidade é gerada em uma usina, ela é produzida em uma tensão muito alta para minimizar perdas durante a transmissão por longas distâncias. As subestações recebem essa eletricidade de alta tensão e a transformam em níveis de tensão adequados para distribuição aos consumidores finais. Nesse processo, diversos equipamentos são necessários. Nele, existem os transformadores, que são os principais equipamentos responsáveis por essa transformação. Eles elevam a tensão da eletricidade recebida das usinas para tornar a transmissão mais eficiente, reduzindo as perdas de energia no processo. Em seguida, essa eletricidade passa por disjuntores, que protegem o sistema contra sobrecargas e curtos-circuitos, interrompendo o fluxo de corrente elétrica em caso de emergência. Além disso, as subestações também contam com chaves seccionadoras, que permitem isolar partes do sistema elétrico para manutenção ou reparo sem interromper o fornecimento de energia para outras áreas. Os relés de proteção monitoram constantemente o sistema elétrico em busca de falhas e anomalias, acionando os dispositivos de proteção quando necessário para evitar danos aos equipamentos ou interrupções no fornecimento de energia. Os capacitores são usados para corrigir o fator de potência e melhorar a eficiência do sistema, enquanto os reatores de núcleo de ar ajudam a controlar o fluxo de energia e estabilizar a tensão. Todos esses componentes trabalham juntos para garantir que a eletricidade seja transmitida e distribuída de forma segura, confiável e eficiente, atendendo às demandas dos consumidores finais e contribuindo para o funcionamento adequado do sistema elétrico como um todo. Existem também os reatores de núcleo de ar, eles são utilizados principalmente em sistemas de alta tensão para controlar correntes de curto-circuito e proteger equipamentos sensíveis (SEN, 2021).

2.2 Redes Neurais

As redes neurais artificiais são modelos computacionais inspirados no funcionamento do cérebro humano, compostos por neurônios interconectados que processam informações. Elas são amplamente utilizadas em diversas áreas, como reconhecimento de padrões, processamento de linguagem natural, visão computacional e muitas outras aplicações de aprendizado de máquina. Em Rumelhart, Hinton e Williams (1986), descreve-se pioneiramente o algoritmo de retropropagação, fundamental para o treinamento de redes neurais profundas.

Sua estrutura é composta por unidades básicas chamadas de neurônios ou nós, que são organizados em camadas interconectadas. Existem três tipos principais de camadas em uma rede neural: camada de entrada, camadas ocultas e camada de saída.

- **Camada de Entrada:** Esta é a camada que recebe os dados de entrada. Cada nó nesta camada representa uma característica ou atributo dos dados que estão sendo alimentados na rede neural. Por exemplo, em uma aplicação de reconhecimento de imagens, cada nó na camada de entrada pode representar um pixel da imagem.
- **Camadas Ocultas:** Estas são as camadas intermediárias entre a camada de entrada e a camada de saída. Cada neurônio em uma camada oculta recebe entradas das camadas anteriores, realiza algum tipo de transformação não linear dessas entradas e passa o resultado para a próxima camada. A presença de múltiplas camadas ocultas permite que a rede aprenda representações complexas e abstratas dos dados.
- **Camada de Saída:** Esta é a camada final da rede neural que gera as saídas desejadas. A estrutura da camada de saída depende do tipo de problema que está sendo resolvido. Por exemplo, em um problema de classificação, cada nó na camada de saída pode representar uma classe diferente, e a saída pode ser interpretada como a probabilidade de pertencer a cada classe.

O funcionamento básico de uma rede neural ocorre em duas fases principais: propagação para a frente (forward propagation) e retropropagação do erro (backpropagation).

- **Propagação para a Frente:** Durante esta fase, os dados são alimentados na rede neural através da camada de entrada e propagam-se através das camadas ocultas até a camada de saída. Cada neurônio em cada camada aplica uma transformação às suas entradas e passa o resultado para os neurônios na próxima camada.
- **Retropropagação do Erro:** Após a propagação para a frente, a rede compara as saídas previstas com as saídas reais desejadas e calcula a diferença entre elas, chamada de erro. Em seguida, esse erro é propagado de volta através da rede, começando pela camada de saída e indo em direção à camada de entrada. Durante essa retropropagação, os pesos das conexões entre os neurônios são ajustados de acordo com o gradiente do erro em relação aos pesos, usando um algoritmo de otimização como o gradiente descendente, a fim de minimizar o erro global da rede.

Essencialmente, as redes neurais aprendem iterativamente ajustando os pesos de suas conexões através do processo de treinamento, onde são apresentados a um conjunto de dados de entrada e as correspondentes saídas desejadas. Com o tempo, a rede neural é capaz de aprender a mapear efetivamente os padrões nos dados de entrada para as saídas

desejadas, tornando-se assim capaz de realizar tarefas como reconhecimento de padrões, classificação, regressão, entre outros.

2.2.1 You Look Only Once

YOLO (You Only Look Once) é um modelo de detecção de objetos em imagens e vídeos em tempo real, que se destaca por sua eficiência e precisão. Desenvolvido por Joseph Redmon, Santosh Divvala, Ross Girshick e Ali Farhadi, o YOLO aborda o problema de detecção de objetos como uma única tarefa de regressão, prevendo caixas delimitadoras e probabilidades de classe diretamente de imagens inteiras em uma única passagem pela rede neural. O funcionamento do YOLO começa com a divisão da imagem de entrada em uma grade, geralmente de dimensões como 7x7 ou 9x9. Cada célula dessa grade é responsável por prever um conjunto de caixas delimitadoras e as probabilidades das classes dos objetos contidos nessa célula. Para cada célula da grade, o modelo faz previsões sobre as caixas delimitadoras que contêm objetos, representadas por cinco valores: coordenadas (x, y) do centro da caixa, largura (w) e altura (h) da caixa, e a confiança de que a caixa contém um objeto. Além disso, são previstas as probabilidades de cada classe para cada caixa delimitadora. Após a predição das caixas delimitadoras, o YOLO utiliza um processo chamado Non-max Suppression (Supressão de Não-Máximo) para refinar as previsões e eliminar caixas sobrepostas ou redundantes, mantendo apenas as detecções mais confiáveis. Esse processo envolve a supressão de caixas que têm uma sobreposição significativa e a escolha da caixa com a maior confiança entre as caixas sobrepostas. A saída do YOLO é uma lista de caixas delimitadoras, cada uma associada a uma classe prevista e sua confiança. Essas caixas delimitadoras representam os objetos detectados na imagem, fornecendo informações sobre sua localização e classificação. Em resumo, o YOLO oferece uma abordagem eficaz e eficiente para a detecção de objetos em tempo real, consolidando-se como uma ferramenta valiosa em diversas aplicações, desde sistemas de segurança até veículos autônomos (REDMON et al., 2016).

2.2.2 Batch

Um dos aspectos cruciais do funcionamento da YOLO é o conceito de "batch" (em tradução livre, "lote") durante o treinamento da rede neural. Ao agrupar várias imagens em lotes para processamento simultâneo, a YOLO aproveita a capacidade de processamento paralelo das GPUs, acelerando significativamente o treinamento. Durante a propagação direta, cada imagem no lote é processada pela rede neural para gerar previsões de detecção de objetos. Em seguida, a perda é calculada em relação às anotações verdadeiras, e os pesos da rede são atualizados para minimizar essa perda, usando algoritmos de otimização como o gradiente descendente. Esse processo é repetido para vários lotes de imagens até que a rede convirja para uma solução adequada. Assim, o uso eficiente de lotes na YOLO

não apenas acelera o treinamento, mas também contribui para a robustez e eficácia dos modelos de detecção de objetos resultantes. (GOODFELLOW; BENGIO; COURVILLE, 2016)

2.2.3 Otimizadores

Falar sobre o Otimizadores.....!!!

2.2.4 Precisão e Recall

A fim de avaliar o desempenho de um treinamento na arquitetura YOLO, é preciso entender os resultados fornecidos pelo modelo. De acordo com (PADILLA; NETTO; SILVA, 2020), basicamente a YOLO utiliza a métrica chamada Average Precision (AP) (“Precisão Média”, em tradução livre). Ela se baseia no conceito de IoU (“Intersection over the Union”, Intersecção sobre a União, em tradução livre), que calcula uma razão entre a interseção da detecção feita pelo algoritmo com relação à marcação (bounding box) realizada em cima da área dividida pela união dessas duas áreas (Figura 1). Essa razão poderá ser comparada com um valor pré-estabelecido, o thresholds, que será referido por L. A partir desse valor, é possível que no processo de detecção retorne três diferentes resultados na pesquisa pela classe desejada. São eles: Verdadeiro Positivo (VP), Falso Positivo (FP) e Falso Negativo (FN). VP trata-se dos resultados considerados corretos que a rede neural retorna, que seriam todos resultados que $\text{IoU} > L$. FP já seriam os resultados em que $\text{IoU} < L$, que são tidos como incorretos. FN, por sua vez, trata dos resultados totalmente fora do esperado.

$$\text{Recall} = \frac{VP}{VP + FN} \quad (1)$$

$$\text{Precisão} = \frac{VP}{VP + FP} \quad (2)$$

Com esses valores, pode-se calcular os resultados da saída que o treinamento da rede YOLO fornece. Em (1), tem-se o cálculo da Recall, que calcula a capacidade da rede de detectar todos os objetos relevantes em uma imagem. Já a Precisão (2), refere-se à capacidade da rede de encontrar apenas resultados relevantes.

A arquitetura YOLO disponibiliza um dataset, ou seja, um banco de imagens e weights, comum em todas as versões, chamado de COCO (“Common Objects in Context”, que em tradução livre seria “Classes Comuns de Objetos”) com classes pré-treinadas e imagens para realização de treinamentos. A partir dele, verificou-se por meio de testes a eficiência das quatro últimas versões da YOLO, a fim de identificar se nas mais recentes houve melhoras significativas em termos de performance e precisão. Na Figura 1, é apresentado o comparativo das versões. Nota-se que a v8, para um menor número de




Figure 1 – Cálculo de IoU. (PADILLA; NETTO; SILVA, 2020)

parâmetros que as demais, apresentou uma mAP50-95, maior que nas versões v5, v6 e v7. Além disso, com relação a velocidade de processamento, a v8 também se sobressai, com maior rapidez no processamento, ao processar maior quantidade de imagens para um mesmo intervalo de tempo (PADILLA; NETTO; SILVA, 2020).




Figure 2 – Aumento de desempenho da precisão média, versão 5 para 8. (JOCHER; CHAURASIA; QIU, 2023)

2.3 Realidade Virtual

A realidade virtual é uma tecnologia que permite aos usuários imergirem em ambientes virtuais tridimensionais, geralmente através do uso de dispositivos como óculos de realidade virtual (VR) ou capacetes. Desde suas primeiras manifestações nas décadas de 1960 e 1970, quando ainda era experimental e limitada, a realidade virtual tem evoluído consideravelmente. No entanto, foi na década de 1990 que essa tecnologia começou a ganhar destaque comercial, com o lançamento de dispositivos como o Virtual Boy da

Nintendo e os primeiros sistemas de realidade virtual para computadores pessoais. Desde então, a realidade virtual tem sido aplicada em uma variedade de campos, incluindo jogos, simulações, treinamento, educação e terapia. Sua popularidade continuou a crescer com o avanço da tecnologia, oferecendo experiências cada vez mais imersivas e acessíveis (KIRNER; KIRNER, 2011).

2.4 Considerações finais

Neste capítulo, foi apresentado o arcabouço teórico necessário para o entendimento da proposta dessa dissertação. A apresentação das redes neurais, e em específico, o modo que a arquitetura da YOLOv8 sobrepõe-se em termos de eficiência em relação às demais arquiteturas abordadas em outros trabalhos científicos, demonstra o direcionamento assertivo deste trabalho. Além disso, a apresentação da Realidade Virtual como uma disciplina inovadora e muito útil para servir à diversos propósitos dentro da indústria e ciência, corroboram para o entendimento da proposta desta dissertação.

Bibliography

- GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. *Deep learning*. [S.l.]: MIT press, 2016. Citado na página 7.
- JOCHER, G.; CHAURASIA, A.; QIU, J. *YOLO by Ultralytics. Ultralytics*. 2023. Citado 2 vezes nas páginas 9 and 8.
- KIRNER, C.; KIRNER, T. G. Evolução e tendências da realidade virtual e da realidade aumentada. *Realidade Virtual e Aumentada: Aplicações e Tendências*. Cap, v. 1, p. 10–25, 2011. Citado na página 9.
- LIMA, M. E. A.; OLIVEIRA, R. C. Precarização e acidentes de trabalho: os riscos da terceirização no setor elétrico. *Revista Brasileira de Saúde Ocupacional*, SciELO Brasil, v. 46, p. e6, 2021. Citado na página 1.
- OĞCU, G.; DEMIREL, O. F.; ZAIM, S. Forecasting electricity consumption with neural networks and support vector regression. *Procedia-Social and Behavioral Sciences*, Elsevier, v. 58, p. 1576–1585, 2012. Citado na página 2.
- PADILLA, R.; NETTO, S. L.; SILVA, E. A. D. A survey on performance metrics for object-detection algorithms. In: IEEE. *2020 international conference on systems, signals and image processing (IWSSIP)*. [S.l.], 2020. p. 237–242. Citado 3 vezes nas páginas 9, 7, and 8.
- PALMEIRA, E. G. Q. et al. O uncanny valley das mãos virtuais em aplicações de realidade virtual imersiva: uma revisão sistemática da literatura. *Revista Ibérica de Sistemas e Tecnologias de Informação*, Associação Ibérica de Sistemas e Tecnologias de Informacao, n. E31, p. 497–512, 2020. Citado na página 2.
- RANDOLPH, J. Electric power substations engineering [book reviews]. *IEEE Power and Energy Magazine*, IEEE, v. 11, n. 3, p. 103–105, 2013. Citado na página 1.
- REDMON, J. et al. You only look once: Unified, real-time object detection. In: *Proceedings of the IEEE conference on computer vision and pattern recognition*. [S.l.: s.n.], 2016. p. 779–788. Citado na página 6.
- RUMELHART, D. E.; HINTON, G. E.; WILLIAMS, R. J. Learning representations by back-propagating errors. *nature*, Nature Publishing Group UK London, v. 323, n. 6088, p. 533–536, 1986. Citado na página 4.
- SEN, P. C. *Principles of Electric Machines and Power Electronics, International Adaptation*. [S.l.]: John Wiley & Sons, 2021. Citado na página 4.
- ZHOU, K.; FU, C.; YANG, S. Big data driven smart energy management: From big data to big insights. *Renewable and sustainable energy reviews*, Elsevier, v. 56, p. 215–225, 2016. Citado na página 2.